

# AutoEncoder ile Seralarda Anomali Tespiti

Şevket AY  
Sakarya Uygulamalı Bilimler  
Üniversitesi  
Sakarya, Türkiye

**Abstract**—Çeşitli meyve ve sebze yetiştirilen seralarda akıllı otomasyon sistemleri oldukça önemlidir. Yetiştirilen ürün için takip sistemleri mevcuttur ve bu ürünlerin sağlıklı bir şekilde yetişmesi için parametreler hassas bir şekilde takip edilmelidir. Olası bir anormal durumda çok fazla vakit geçmeden müdahale edilmelidir. Bu amaçla çalışma boyunca LSTM ve CNN AutoEncoder modelleri eğitilmiştir. İç Sıcaklık, Dış Sıcaklık ve Dış Nem parametreleri için anomali tespiti yapılmıştır.

**Keywords**—CNN, LSTM, autoencoder, deep learning

## I. GİRİŞ

Meyve, sebze ve çiçek türlerinin örtüsü altında yetiştirme, geleneksel seradan, şu anda modernliği ve yüksek otomasyon seviyesi ile bilinen tarımsal-endüstriyel seraya doğru gelişmiştir. Seradaki iklim değişkenlerini (sıcaklık, nem, CO<sub>2</sub> konsantrasyonu, vb.) kontrol etmek ve düzenlemek için cihazların kullanımı dahil olmak üzere yeni teknikler ortaya çıkmıştır. Dünya nüfusu, sağlıklı taze gıda talebiyle birlikte hızla artmaktadır. Sera endüstrisi, vitamin ve mineral bakımından yüksek meyve ve sebzeler gibi taze gıda sağlamada önemli bir rol oynayabilir. Seralar, birim ürün başına yüksek su kullanım verimliliği ile birlikte alan başına yüksek mahsul üretimine izin verir. Dünya çapında, örtü altı üretim alanı artmaktadır. Bununla birlikte, sera endüstrisi, mahsul üretimini yönetmek için yeterli vasıflı işgücü bulmakta zorluklarla karşılaşmaktadır. Bir mahsul yöneticisi, mahsul büyümesini kontrol etmek için yüksek düzeyde bilgi ve deneyime sahip olmalıdır. Çiftlikler büyüdükçe, çeşitli sera bölümlerinin tüm ayrıntılarını izlemek daha zorlu hale geliyor. Ayrıca, kaynaklar (su, fosil enerji) giderek azalıyor ve bu da maksimum kaynak verimliliğine acilen ihtiyaç duyulmasına neden oluyor. Bir sera, mahsulü yağmur, rüzgar, düşük sıcaklıklar veya haşereler gibi dış etkilere korur. Modern bir yüksek teknoloji serası, uygun bir büyüme iklimi yaratmak için aktüatörlerin (örneğin ısıtma, aydınlatma, sulama) aktif kontrolü ile donatılmıştır. Elbette bu, kaynak tüketimi (örneğin yakıt, elektrik, su) pahasına gelir. Yetiştirici, iklim ve sulama stratejisini belirler ve tüm iklim ve sulama parametreleri için ayar noktalarını tanımlar. Aktüatörler, ayar noktalarına göre çalıştırılır ve sensörler, kontrol döngüsü için ölçülen veriler hakkında geri bildirim verir. Otomatik sera iklimi kontrol algoritmaları onlarca yıl önce geliştirilmiştir. Günümüzde modern yüksek teknoloji seralar, yetiştirici tarafından manuel olarak ayarlanan ayar noktalarına dayalı olarak sera aktüatörlerini kontrol edebilen süreç bilgisayarları ile donatılmıştır. Daha fazla otomatik kontrol eklemek için çeşitli sera iklimi ve mahsul modelleri geliştirilmiştir. Günümüzün sera iklimi modellerine genel bir bakış önceki bir çalışmada verilmiştir. Sera bitkisi modellerine ve modelleme yaklaşımlarına genel bir bakış, diğer çalışmalarda verilmektedir. Ayar noktalarının otomatik olarak belirlenmesi ve yetiştiricinin kararını devralması için dinamik sera iklimi modelleri ve dinamik mahsul modelleri kullanılmıştır. İklim ve mahsul simülasyon modelleri birleştirilir ve bir seranın sensörlerine ve aktüatörlerine bağlanırsa, sera iklimi ve

mahsul büyümesi otomatik algoritmalarla kontrol edilebilir. Bu tür deneyler Hollanda'da domates ve tatlı biberle başarıyla gerçekleştirilmiştir. Bu deneyde, iklim simülasyonları için dış hava koşulları ve hava tahminleri kullanılmıştır. Mahsul büyüme simülasyonları, farklı ayar noktaları için daha fazla mahsul büyümesini ve gelişimini tahmin etmek için mahsul döngüsü ile birlikte gerçekleştirildi. Optimum set daha sonra serada otomatik olarak uygulanmıştır. Hesaplamalar her gün tekrarlanmış ve bu şekilde optimum kontrol stratejisi ile ürünler yetiştirilmiştir. Domates ile daha önce başka deneyler yapılmıştır. Bir yetiştiricinin kararlarının bir kısmını devralmanın bir başka yolu da sera iklim kontrolü için makine öğrenimi algoritmalarını kullanmaktır. K-algoritmaları, Bayes ağları, destek vektör makineleri regresyonu, sinir ağları, pekiştirmeli öğrenme veya genetik algoritmalar. Bununla birlikte, bilgimize göre, makine öğrenimi henüz iklim ve sulamayı kontrol etmek ve ticari uygulama ile karşılaştırılabilir verim seviyeleri ile daha uzun bir süre boyunca bir sera ürününü bağımsız olarak yetiştirmek için ürün yönetimi kararları almak için kullanılmamıştır. Öte yandan, yapay zekanın (AI) kullanımı, tıbbi uygulamalar, otonom arabalar veya robotik gibi günlük yaşamın ve toplumun çeşitli alanlarında büyük atılımlara ulaşmıştır.


## II. MATERYAL VE YÖNTEMLER

### A. Veri Kümesi

Veri seti Antalya'da bir serada kurulu olan otomasyon sistemindeki sensörler aracılığıyla birer dakikalık aralar ile veri tabanına API aracılığıyla çekilmektedir. Veri tabanı bir sunucuda MongoDB kullanılarak oluşturulmuştur. Bu çalışma esnasında kullanılan veri sayısı 68.718'dir. Veriler 2022-03-05 ile 2022-05-22 tarihleri arasında toplanan verileri içermektedir. Veri seti 9 adet parametreyi içermektedir. Bu parametreler İç Sıcaklık, Dış Sıcaklık, İç Nem, Dış Nem, Çatı Güney, Çatı Kuzey, Kuzey Havalandırma, Güney Havalandırma ve Rüzgar Hızı'dır. İç Sıcaklık grafiği Şekil 1'de gösterilmiştir.

### B. OtoKodlayıcı (AutoEncoder)

Otomatik kodlayıcı, verilerin nasıl verimli bir şekilde sıkıştırılacağını ve kodlanacağını öğrenen, ardından verilerin indirgenmiş kodlanmış gösteriminden orijinal girdiye mümkün olduğunca yakın bir temsile nasıl yeniden yapılandırılacağını öğrenen denetimsiz bir yapay sinir ağıdır. OtoKodlayıcı, tasarım gereği, verilerdeki gürültünün nasıl yok sayılacağını öğrenerek veri boyutlarını azaltır. OtoKodlayıcı'nın bileşenleri Kodlayıcı, Gizli Boşluk (Dar Boğaz), Kod Çözücü'dür. Kodlayıcı; modelin girdi boyutlarını küçültür ve girdiyi sıkıştırır. Gizli Boşluk; giriş verilerinin en düşük boyutlu halidir. Bu katmanda veri gürültüden arınmış bir şekilde bulunur. Verilerin özelliklerinin en iyi öğrenildiği ve kalıplarının bulunduğu noktadır. Bu gizli boşluk verinin en iyi temsil edildiği katmandır. Kod Çözücü; gizli boşluktan sıkıştırılan veriyi alan ve veriyi yeniden inşa eden kısımdır.

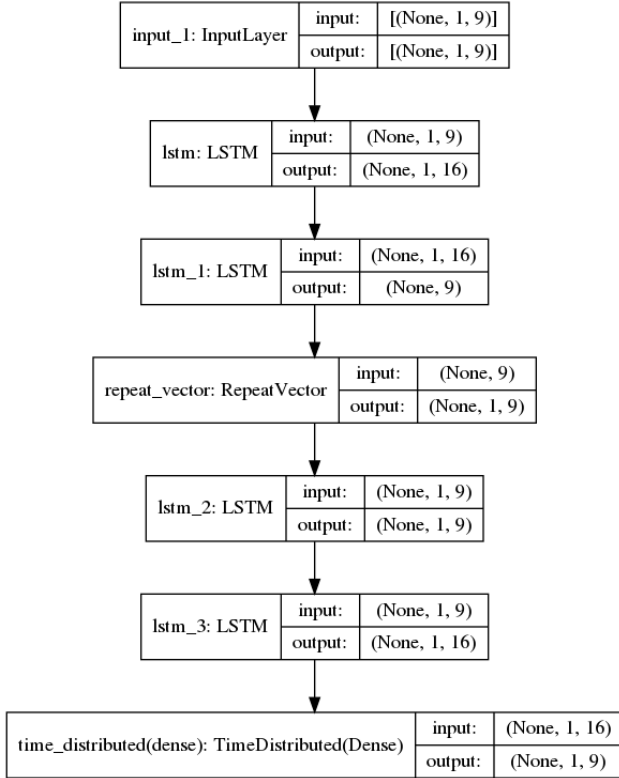


Şekil 1. İç Sıcaklık

### C. LSTM OtoKodlayıcı

Bir LSTM AutoEncoder, bir Kodlayıcı–Kod Çözücü LSTM mimarisi kullanan dizi verileri için bir OtoKodlayıcı uygulanmasıdır. Belirli bir dizi veri kümesi için, bir Kodlayıcı-Kod Çözücü LSTM, giriş dizisini okumak, kodlamak, kodunu çözmek ve yeniden oluşturmak üzere yapılandırılır. Modelin performansı, modelin girdi sırasını yeniden oluşturma yeteneğine göre değerlendirilir.

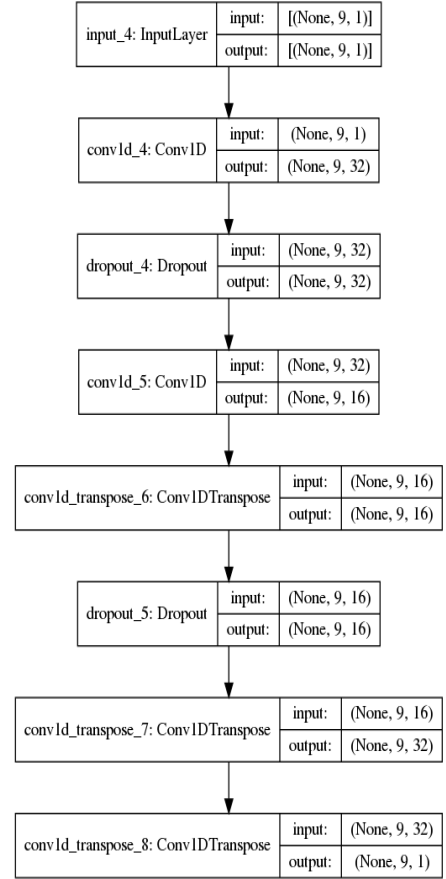
Bırakma (Dropout), fazla sığdırmayı azaltmak için bir katmandaki girdileri kaldırır. Katmana RepeatVector eklemek, girdiyi n defa tekrarlaması anlamına gelir. TimeDistibuted katmanı, bilgiyi önceki katmandan alır ve çıktı katmanlarının uzunluğuna sahip bir vektör oluşturur. Şekil 2’de uygulanan modelin mimarisi verilmiştir.



Şekil 2. LSTM OtoKodlayıcı

### D. CNN OtoKodlayıcı


Evrişimli Otomatik Kodlayıcı, evrişim filtrelerinin denetimsiz öğrenimi için araçlar olarak kullanılan Evrişimli Sinir Ağlarının bir çeşididir. Genellikle, optimal filtreleri öğrenerek yeniden yapılandırma hatalarını en aza indirmek için veriyi yeniden oluşturma görevinde uygulanırlar. Bu görevde eğitildiklerinde, özellikleri çıkarmak için herhangi bir girdiyi uygulanabilirler. Şekil 3’de uygulanan modelin mimarisi verilmiştir.



Şekil 3. CNN OtoKodlayıcı


### III. MODEL DEĞERLENDİRME

OtoKodlayıcı girişte aldığı özellikleri çıkışta yeniden inşa etmeye çalışmaktadır. Bu yüzden OtoKodlayıcı özellikle anormali tespiti için kullanılacaksa bir regresyon probleminde olduğu gibi  $r$  square değeri ile ya da sınıflandırma probleminde olduğu gibi fl skor ile değerlendirilmemektedir. Elbette başarımlar kullanılabilir fakat bu çalışmada model değerlendirilirken normal dağılımdan faydalanılmıştır.




Şekil 4. Normal Dağılım


Model eğitim sonrasında tahmin gerçekleştirdiği zaman tahmin ettiği özelliklerin giriş için aldığı özelliklere çok yakın olması gerekir. Eğer model tahmin ettiği bir veriyi, girişte aldığı halinden çok başka bir konumda tahmin ediyorsa bu normal dağılıma uygun olmayacaktır. Dolayısıyla normal dağılım'da  $3 \times$  standart sapma dışında kalan veriler anormali olarak belirlenmektedir. Şekil 5'de LSTM Otokodlayıcı'nın eğitim grafiği, normal dağılım grafiği ve eşik değeri üzerinde kalan veriler gösterilmiştir.



(a) Eğitim grafiği




(b) Kayıp Dağılımı




(c) Eşik Değer ve Loss Değerleri

Şekil 5. LSTM Otokodlayıcı grafikleri


Şekil 5 (c)'de gösterilen eşik değeri normal dağılıma göre  $3 \times \sigma$  ile belirlenmiştir. Şekil 6'da İç Sıcaklık, Dış Sıcaklık ve Dış Nem için anormali tespit edilen noktalar grafikler üzerinde kırmızı noktalar ile gösterilmiştir.



(a) İç Sıcaklık Anormali




(b) Dış Sıcaklık Anormali

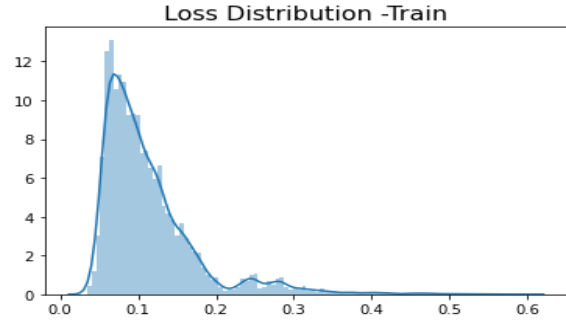


(c) Dış Nem Anormali


Şekil 6'da CNN OtoKodlayıcı'nın eğitim grafiği, normal dağılım grafiği ve eşik değeri üzerinde kalan veriler gösterilmiştir.



(a) Eğitim Grafiği




(b) Kayıp Dağılımı

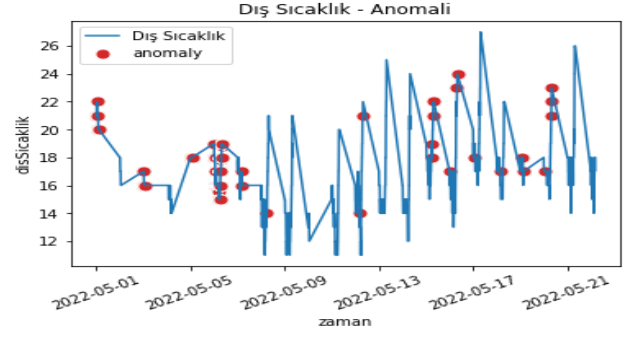


(c) Eşik Değer ve Loss Değerleri

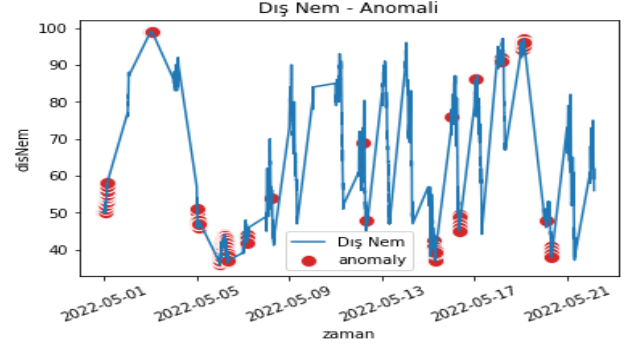
Şekil 7'de İç Sıcaklık, Dış Sıcaklık ve Dış Nem için anormal tespit edilen noktalar grafikler üzerinde kırmızı noktalar ile gösterilmiştir.



(a) İç Sıcaklık – Anomali



(b) Dış Sıcaklık Anomali



(c) Dış Nem Anomali

Her iki modelde incelendiği zaman özellikle Dış Nem parametresi için daha iyi sonuçlar elde edildiği gözlenmektedir.

#### IV. SONUÇ VE TARTIŞMA

Bu çalışmada iki farklı OtoKodlayıcı modeli oluşturulmuştur ve anormal tespiti yapılmak istenmiştir. Çalışmada kullanılan özellikler 9 adettir ve seradan birer dakikalık aralık ile toplanmaktadır. Bu çalışmanın amacı yetiştirilmesi hassas takip gerektiren meyve ve sebzelerin kontrollerini tam akıllı hale getirmektir. Üzerinde tespit yapılan İç Sıcaklık, Dış Sıcaklık ve Dış Nem parametrelerinde anormal bir durum görülmesi halinde sistem havalandırmaların çalışmasını ve çatıların açılıp kapanmasını sağlayacaktır. Çalışma model eğitiminden havalandırma parametreleri, çatı parametreleri çıkarılarak, AutoEncoder mimarisi geliştirilerek, veri sayısı artırılarak, pencere sistemi oluşturularak ve Dış Sıcaklık parametresindeki 10 bin küsur, 130 derece olarak sensörden yanlış okunan değerlerin eğitime alınmaması ile geliştirilebilir.